

Rola harmoniczności w przetwarzaniu informacji o melodii w naturalnych sekwencjach muzycznych

maj 2027

Badanie zaplanowane jest w planie 2×2 (harmoniczność, “muzyczność”). Wiedząc, że fałsz w melodii powoduje błąd predykcji, chcemy sprawdzić jak harmoniczność oraz “muzyczność” słuchacza moderuje wielkość błędu predykcji. Badanie jest prowadzone na dwóch grupach: muzyków* i niemuzyków. → będziemy badali odpowiedź mózgową na aplikowane bodźce, które mamy nadzieję wywołają zauważalne w EEG błędy predykcji

H1: W melodii nieharmonicznej błąd predykcji będzie mniejszy (poprzez precision weighting).

H2: U muzyków obserwujemy większy błąd predykcji.

H3: Interakcja bycia muzykiem z harmonicznością.

częściowa replikacja takiej oto pracy



Melodia to dźwięki, które są oddzielone od siebie pewnymi interwałami (tj. konkretnymi odległościami). W toku życia nabywamy różne wzorce jakie dźwięki z jakim prawdopodobieństwem występują po sobie.

Paradygmat będzie obejmował sekwencje dźwięków (melodii), gdzie część będzie z fałszem, a część bez. Trudnością w jego tworzeniu jest problem modelowania muzyki (choć mamy sporo dobrze opisanych w literaturze modeli), gdzie określamy prawdopodobieństwo występowania po sobie dźwięków.→ będziemy korelować prawdopodobieństwo wystąpienia danych nutek z ERP

*muzyków będziemy rekrutować wg kryteriów MIB.

▼ artykuły

<https://linkinghub.elsevier.com/retrieve/pii/S0149763422004961> → Basinski et. al, 2023

<https://elifesciences.org/articles/51784> → Quiroga-Martinez et. al, 2020 (TRF)

<https://elifesciences.org/articles/51784> → Giovanni M Di Liberto et. al, 2020 (TRF)

teoria

▼ modelowanie muzyki

[IDyOM \(Information Dynamics of Music\)](#)

<https://github.com/mtpearce/idyom>

<https://github.com/mtpearce/idyom/wiki>

IDyOM (Information Dynamics of Music) is a system for constructing multiple-viewpoint, variable-order Markov models for predictive modelling of probabilistic structure in symbolic, sequential auditory domains such as music. IDyOM acquires knowledge about a domain through statistical learning and generates conditional probability distributions representing the estimated likelihood of each event in a sequence, plus associated information-theoretic measures, given the preceding context and prior short- and long-term training of the model.

obliczeniowy model przewidywania w percepcji muzyki, opracowany głównie przez Marcus T. Pearce. [marcus-pearce.com+2PubMed+2](#) → IDyOM -pozwala na okieslenie danej nutki w kontekscie melodii oraz prawdopodobienstwo w kontekscie calej muzyki wschodnioeuropejskiej

głównie idee:

- słuchacz – poprzez ekspozycję na muzykę – uczy się statystycznych regularności stylu muzycznego. [PubMed+1](#)
- podczas słuchania utworu muzycznego, model ciągle generuje **rozkład prawdopodobieństwa** dla kolejnych zdarzeń muzycznych (np. nuty, akordu) na podstawie kontekstu
- na podstawie tego rozkładu wyprowadza się miary informacyjne: m.in. **information content** (IC, czyli miara zaskoczenia) oraz **entropy** (niepewność predykcji). [emusicology.org+1](#)
- model łączy **komponent długoterminowy** (long-term model, wyuczony z dużego korpusu muzyki) oraz **komponent krótkoterminowy** (short-term model, uczący się w trakcie aktualnie słuchanego utworu).

założenia i mechanizmy IDyOM:

1. Symboliczna reprezentacja muzyki

- Utwory są przetworzone w formie symbolicznej (np. MIDI lub inny zapis nutowy), nie bezpośrednio jako dźwięk akustyczny z falą. [SpringerLink +1](#)
- Z każdego zdarzenia muzycznego (np. nuty) wyprowadza się różne cechy („viewpoints”), np. wysokość dźwięku (pitch), kontur melodii (melodic contour), stopień skali (scale degree), rytm, itp. [marcus-pearce.co... +1](#)

2. Model typu zmiennego rzędu (Variable-Order Markov Model, VOMM)

- Model opiera się na algorytmie tak zwanym „Prediction by Partial Match” (PPM) lub podobnym, który analizuje n-gramy różnej długości (historia może być krótka lub długość kontekstu może się zmieniać). [marcus-pearce.co... +1](#)
- Dla każdej możliwej kontynuacji obliczane jest prawdopodobieństwo $P(x_t|x_{t-k}^{t-1})$ dla różnych wartości k (długości historii) i różnych „viewpoints”. [eLife +1](#)

3. Łączenie modeli długoterminowego i krótkoterminowego

- **Long-Term Model (LTM)**: wytrenowany na dużym zbiorze muzyki, reprezentuje ogólne statystyki stylu muzycznego (np. proponowane dla kultury muzycznej zachodniej). [research.gold.ac.uk +1](#)
- **Short-Term Model (STM)**: uczy się online z aktualnie słuchanego utworu, czyli adaptuje się do bieżących wzorców w utworze. [marcus-pearce.co... +1](#)
- Predykcje obu komponentów są mieszane (np. ważone) w celu uzyskania ostatecznej predykcji dla kolejnego zdarzenia muzycznego. [marcus-pearce.co... +1](#)

4. Miary informacyjne

- **Information Content (IC)**: jest to miara „zaskoczenia” dla danego zdarzenia: $IC = -\log_2 P(\text{zdarzenie}|\text{kontext})$. Bardziej niespodziewane zdarzenie → wyższe IC. [PubMed +1](#)
- **Entropy**: miara niepewności rozkładu predykcji dla następnego zdarzenia: gdy wiele zdarzeń są porównywalnie prawdopodobne, entropia jest wysoka. [emusicology.org](#)

przydatne linki:

IDyOMpy DOCUMENTATION → <https://guimarion.github.io/IDyOMpy/html/index.html>

<https://github.com/GuiMarion/IDyOMpy>

<https://github.com/mtpearce/idyom/wiki>

<https://github.com/mtpearce/idyom/wiki/IDyOM-Parameters>

<https://github.com/mtpearce/idyom/wiki/IDyOM-Output>

wykorzystanie modelu

A. PARAMETRY

Required parameters

- `dataset-id` : a dataset id, (an integer, e.g., 0)
- `target-viewpoints` : a list of basic viewpoints to predict, e.g. '(cpitch) or '(cpitch onset)
- `source-viewpoints` : a list of viewpoints to use in prediction, e.g. '((cpintfref cpint) ioi) to use two viewpoints: cpintfref linked with cpint and ioi; or '(cpintfref cpint ioi) to use three unlinked viewpoints: cpintfref, cpint, and ioi

lista vievpoints: <https://github.com/mtpearce/idyom/wiki/List-of-viewpoints>

Statistical modelling parameters

See [Pearce \(2005, chapter 6\)](#) for further description and explanation of these parameters.

- `models` : the type of IDyOM model to use. Options are:
 - `:stm` - short-term model only, trained on the current composition.
 - `:ltm` - long-term model only, trained on the pretraining and resampling training data.
 - `:ltm+` - the long-term model, with additional incremental training on the test set;
 - `:both` - a combination of `:stm` and `:ltm`;
 - `:both+` - a combination of `:stm` and `:ltm+` (this is the default).

B. OUTPUT

model

proponowane wysokości dźwięków

D-REX Model (*The Dynamic Regularity Extraction*)

<https://github.com/JHU-LCAP/DREX-model>

The Dynamic Regularity Extraction (D-REX) model is a computational model for predictive processing in auditory perception of sequential sounds. Based in Bayesian inference and theories of predictive coding, the model provides a framework for exploring the computational processes behind predictive coding in complex scenes.

Given a sequence of continuous-valued inputs along any acoustic or perceptual dimension (e.g., pitch, energy), the model produces a prediction at each time given the observed inputs.

This probabilistic prediction is based on a statistical representation of structure (i.e., *regularities*) in the observed sequence. Importantly, the model does not assume stationarity in the input (hence, *dynamic*); rather, the model collects many statistical representations over different context windows (termed *context hypotheses*). These contexts are then weighted by beliefs, or evidence for each context window from the observed sequence. Here is an illustration of how the model builds these robust predictions (taken from [\[1\]](#)):

🔧 Jak działa model D-REX? (w skrócie)

1. Model dostaje sekwencję dźwięków (np. tonów, sygnałów).
2. Zakłada, że dźwięki są losowane z pewnego rozkładu prawdopodobieństwa (np. normalnego), który może się zmieniać w czasie.
3. Model analizuje różne długości kontekstu (np. ostatnie 5, 10 czy 20 dźwięków), aby przewidzieć, co będzie dalej.
4. Dostosowuje swoje przekonania w czasie – jeśli coś przestaje pasować do wcześniejszych wzorców, zakłada, że nastąpiła zmiana (change point).
5. Oblicza, na ile zaskakujący był kolejny dźwięk – im bardziej niepasujący, tym większe „surprisal”.


jest to model obliczeniowy zaprojektowany, aby odzwierciedlać sposób, w jaki mózg człowieka wychwytuje regularności w zmieniających się sekwencjach dźwiękowych (np. w muzyce, mowie, otoczeniu dźwiękowym) i **dostosowuje swoje przewidywania**, gdy struktura tych sekwencji się zmienia → opiera się na bayesowskim wnioskowaniu probabilistycznym

- wykrywa zmiany w strukturze statystycznej sekwencji (tzw. "change points"),
- oblicza prawdopodobieństwo wystąpienia kolejnego dźwięku,
- oraz mierzy zaskoczenie (surprisal), czyli jak bardzo dany dźwięk odbiega od oczekiwań

model uwzględnia:

- a. ograniczenia pamięci (*parametr M*)
- b. szum poznawczy (*parametr N*)
- c. złożoność śledzonych statystyk (*parametr D*): model może uwzględniać tylko średnie/wariancje (D=1) albo również współzależności/cowariancje (D=2 lub więcej)

output:



OBSERVATIONS

dane wejściowe do modelu

- wysokość następujących po sobie tonów
- niebieski cień - reprezentuje rozkład prawdopodobieństwa przyjęty przez model dla obserwacji
- żółte/ciemniejsze punkty - mogą oznaczać zidentyfikowane outliery lub punkty większego zaskoczenia – w zależności od konfiguracji

$P(c_i | x_{1:t})$

*prawdopodobieństwo, że granica kontekstu (changepoint) znajdowała się w danym punkcie w przeszłości — innymi słowy, gdzie mogła nastąpić **zmiana struktury statystycznej sekwencji***

- OY - potencjalne punkty początku kontekstu $c_i \in [1, t]$
- heatmap - żółty to wysokie prawdopodobieństwo, że **od tego punktu zaczął się nowy kontekst** (czyli zaszła zmiana w strukturze danych), niebieski = niskie prawdopodobieństwo

SUPRISAL

obliczone przez model zaskoczenie dla każdego kolejnego punktu obserwacji


$$\text{Surprisal}(x_t) = -\log_2 P(x_t | \text{kontekst})$$

- OY - zaskoczenie mierzone w bitach informacji
- wysokie wartości oznaczają, że zdarzenie było nieprzewidywalne według modelu

▼ teoria muzyki

<https://www.youtube.com/watch?v=eA8gTqFrWZ8&t=1025s>

nas korpus muzyczny opiera się na skali chromatycznej, czyli skali 12-dźwiękowej




oktawa - dźwięk 2x wyższy w sensie szybkości fali akustycznej

akord - kilka nut granych w harmonii jednocześnie; najpopularniejsze są trójdźwiękowe (dur: +4 +3, moll: +3 +3)

obwiednia amplitudy

(linijka 2)

A



badanie

▼ main

wyjaśniamy odpowiedź mózgową:

- cechami akustycznymi dźwięku
- parametrami, które wylicza IDyOM

▼ IDyOMpy code

```

### To train/test:
python3 App.py -t trainingFolder/ -s testingFolder/
### To replicate figures from Music of Silence Part II:
python3 App.py -t trainingFolder/ -d testingFolder/
### To change the maximal order to 10:
python3 App.py -t trainingFolder/ -s testingFolder/ -m 10
### To only use the pitch information:
python3 App.py -t trainingFolder/ -s testingFolder/ -v pitch
### To compute genuine entropies and not use the approximation (it takes 5 times longer):
python3 App.py -t trainingFolder/ -s testingFolder/ -g 1
### To compute the training monitoring (c.f. method paper):
python3 App.py -i preTrainingFolder/ -e trainingFolder/
### To only use the long-term model:
python3 App.py -t trainingFolder/ -s testingFolder/ -l 1
### To only use the short-term model:
python3 App.py -t trainingFolder/ -s testingFolder/ -b 1

```


<code>-t TRAIN_FOLDER, --train=TRAIN_FOLDER</code>	Określa folder zawierający dane treningowe — czyli dane, na których model zostanie wytrenowany . guimaron.github.io	<code>-k K_FOLD, --k_fold=K_FOLD</code>	Ustawia liczbę „foldów” (części) do cross-validation, np. k=5 oznacza 5-krotne podziały. Można ustawić k = -1 dla „leave-one-out”. Domyślnie 5. guimaron.github.io
<code>-s TRIAL_FOLDER, --surprise=TRIAL_FOLDER</code>	Określa folder z danymi testowymi, na których obliczana jest miara „surprise” (czyli jak bardzo dany element jest nieoczekiwany względem modelu). guimaron.github.io	<code>-v VIEWPOINTS, --viewPoints=VIEWPOINTS</code>	Określa „viewpoints” (perspektywy) analizy — np. pitch (wysokość dźwięku), length (długość nuty), interval, velocity — domyślnie „pitch,length”. guimaron.github.io
<code>-n TRIAL_FOLDER_SILENT, --silentNotes=TRIAL_FOLDER_SILENT</code>	Określa folder, na którym model ma obliczyć prawdopodobieństwa dla tzw. „silent notes” (pauz lub braków dźwięku) — przydatne w analizie muzycznej. guimaron.github.io	<code>-m MAX_ORDER, --max_order=MAX_ORDER</code>	Maksymalny porządek (order) modelu – np. ile poprzednich stanów jest uwzględniane w modelu probabilistycznym. Domyślnie 20. guimaron.github.io
<code>-d THRESHOLD_MISSING_NOTES, --threshold_missing_notes=THRESHOLD_MISSING_NOTES</code>	Ustawia próg dla wybierania brakujących nut — jeżeli pewien procent nut jest „missing”, model może je traktować odmiennie. Domyślnie 0.2 (20 %). guimaron.github.io	<code>-g GENUINE_ENTROPIES, --genuine_entropies=GENUINE_ENTROPIES</code>	Jeżeli =1, obliczaj prawdziwe entropie (nie tylko przybliżenie). To trwa znacznie dłużej (ok. 5x) ale daje dokładniejsze wyniki. guimaron.github.io
<code>-z ZERO_PADDING, --zero_padding=ZERO_PADDING</code>	Określa, czy używać „zero paddingu” w wyjściu surprise — czyli czy przed i po zdarzeniu wstawić zera w reprezentacji czasowej. guimaron.github.io	<code>-r FOLDER_DUPLICATES, --check_dataset=FOLDER_DUPLICATES</code>	Sprawdź czy w przekazanym folderze nie ma duplikatów plików/danych — przydatne, by dane treningowe/testowe nie powieliły się. guimaron.github.io
<code>-b SHORT_TERM_ONLY, --short_term=SHORT_TERM_ONLY</code>	Jeżeli ustawione =1, używa wyłącznie modelu krótkoterminowego (short-term model). guimaron.github.io	<code>-e TRAIN_TEST_FOLDER, --evolution=TRAIN_TEST_FOLDER</code>	Umożliwia analizę „ewolucji” treningu/modułu: trening na jednym folderze + ewaluacja na innym. guimaron.github.io
<code>-l LONG_TERM_ONLY, --long_term=LONG_TERM_ONLY</code>	Jeżeli ustawione =1, używa wyłącznie modelu długoterminowego (long-term model). guimaron.github.io	<code>-i INITIALIZATION, --init_evolution=INITIALIZATION</code>	Określa folder do inicjalizacji analizy ewolucji (np. wstępne dane) w strategii „evolution training”. guimaron.github.io
<code>-c CROSS_EVAL, --cross_eval=CROSS_EVAL</code>	Włącza ocenę modelu przez podział danych na kawałki i wykonanie k-fold cross-validation („przekrojowej oceny”) na przekazanym zbiorze danych. guimaron.github.io		

▼ kryteria rekrutacji muzyków | niemózyków

muzycy

<https://onlinelibrary.wiley.com/doi/10.1002/ejp.70012> | <https://link.springer.com/article/10.1007/s00429-024-02836-x> | <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0281057> | <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2022.907540/full> | <https://www.nature.com/articles/s41598-021-83135-x#Sec7>

- ukończona szkoła muzyczna (wykształcenie muzyczne)
- stałe praktykowanie gry na instrumencie (tu ile godzin grają tygodniowo?)
- gra lub śpiewa regularnie co najmniej 8 lat
- studenci akademii muzycznej (full time)
- profesjonálni muzycy

niemuzycy

- nie uczyli się w szkole muzycznej dłużej niż rok/pobierali lekcje gry na instrumencie lub wokalu
- nie praktykują na żadnym instrumencie
- nie interesują się muzyką

mogą wypełnić kwestionariusz na formsach kwestionariusz


▼ paradygmat

2 × 2 | muzycy vs niemuzycy X harmoniczny vs changing

▼ TRF (the Temporal Response Function)

kształt zależy od odpowiedzi w czasie

konwolucja → analiza sygnałów biologicznych, które są ciągłe



słowniczek

"sour note detection" - fałszywa nutka

skala diatoniczna - jest to skala składająca się z 7 dźwięków, gdzie 5 z nich to całe tony a 2 to półtony; odległości od dźwięków są ściśle określone